

**LAPORAN PROGRES PROJECT PEMBELAJARAN MESIN DASAR
SEMESTER GENAP 2025/2026**

IDENTITAS PROYEK	
Judul	Deteksi Tingkat Kematangan Buah Kelapa Sawit dari Citra Tandan Menggunakan <i>Convolutional Neural Network</i> dengan Pendekatan Transfer Learning
Topik	Klasifikasi Citra untuk Deteksi Kematangan Buah
Identitas Penyusun	1. Lailil Hidayanti (24031554036) 2. Rahmawati Dian Pratiwi (24031554183) 3. Nurlaila Lutfi Azizah (24051554205)
Kelas	2024E

1. PENDAHULUAN

1.1 Latar Belakang

Kelapa sawit merupakan salah satu komoditas perkebunan paling strategis di Indonesia. Luas area perkebunan kelapa sawit tercatat sekitar 16,83 juta hektar dengan total produksi mencapai 46,82 juta ton, menjadikan Indonesia sebagai penghasil utama *Crude Palm Oil* (CPO) dengan penguasaan lebih dari 55% pangsa ekspor dunia (Kementerian Pertanian RI, 2024). Besarnya kontribusi sektor ini terhadap perekonomian nasional menjadikan efisiensi di setiap tahapan produksi, termasuk proses pemanenan, sebagai hal yang sangat krusial. Salah satu faktor penentu kualitas minyak sawit adalah ketepatan waktu panen, yang bergantung pada kemampuan mendeteksi tingkat kematangan tandan buah segar (TBS). Kesalahan dalam menentukan tingkat kematangan dapat meningkatkan kadar *Free Fatty Acid* (FFA) sehingga menurunkan kualitas minyak dan menimbulkan kerugian ekonomi (Soetrisno et al., 2024).

Selama ini, proses penentuan kematangan TBS masih dilakukan secara manual oleh tenaga kerja terlatih. Metode ini bersifat subjektif, padat karya, dan rentan inkonsistensi antarpekerja, terutama di perkebunan berskala besar (Lai et al., 2023). Oleh karena itu, diperlukan solusi berbasis otomasi yang lebih cepat, akurat, dan konsisten. Perkembangan teknologi computer vision dan deep learning membuka peluang besar untuk mengotomatisasi klasifikasi tingkat kematangan buah sawit. *Convolutional Neural Network* (CNN) mampu mengekstraksi fitur visual secara hierarkis dari citra, termasuk perubahan warna dan tekstur permukaan tandan yang menjadi indikator utama kematangan buah sawit. Kemampuan ini menjadikan CNN unggul dalam tugas klasifikasi citra dengan akurasi mencapai 99,89% serta nilai precision, recall, dan F-measure di atas 99% (Puttinaovarata & Chai-Arayalert, 2024). Untuk mengatasi keterbatasan dataset dan komputasi, pendekatan transfer learning banyak digunakan. Penelitian menunjukkan bahwa ResNet152V2, DenseNet201, MobileNet, dan InceptionV3 mampu mencapai akurasi di atas 0,99 dengan validation loss rendah (Kurniawan et al., 2025). Selain itu, EfficientNetB0 terbukti sebagai CNN

ringan paling akurat, sementara MobileNetV1 menjadi yang tercepat untuk klasifikasi kematangan sawit (Suharjito et al., 2021). Namun, sebagian besar penelitian masih dilakukan dalam kondisi terkontrol dengan dataset yang belum sepenuhnya merepresentasikan kondisi nyata di lapangan. Padahal, kualitas minyak sawit sangat dipengaruhi oleh variasi kondisi nyata di pabrik maupun kebun (Suharjito et al., 2023). Oleh karena itu, penelitian ini menggunakan dataset citra tandan buah sawit dari Roboflow yang lebih representatif untuk menguji performa CNN berbasis transfer learning dalam klasifikasi tingkat kematangan TBS.

1.2 Rumusan Masalah dan Tujuan

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana membangun model klasifikasi tingkat kematangan buah kelapa sawit dari citra tandan menggunakan CNN dengan pendekatan transfer learning?
2. Arsitektur transfer learning manakah yang menghasilkan performa terbaik dalam mendeteksi tingkat kematangan buah kelapa sawit?
3. Seberapa akurat model yang dibangun dalam mengklasifikasikan tingkat kematangan TBS berdasarkan dataset citra yang digunakan?

Adapun tujuan dari penelitian ini adalah:


1. Membangun model deteksi kematangan buah kelapa sawit berbasis citra tandan menggunakan CNN dengan pendekatan transfer learning.
2. Membandingkan performa beberapa arsitektur transfer learning dalam tugas klasifikasi kematangan TBS kelapa sawit.
3. Mengukur performa model terbaik menggunakan metrik evaluasi seperti akurasi, precision, recall, dan F1-score.

2. METODOLOGI

2.1 Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini adalah [palm-fruit-ripeness-classification](#) yang bersumber dari *Roboflow Universe* dengan enam kelas kematangan tandan buah segar (TBS) kelapa sawit yaitu *unripe*, *underripe*, *ripe*, *overripe*, *rotten*, dan *empty_bunch*. Pembagian *train/validasi/test* telah tersedia sehingga *re-split* tidak diperlukan guna mencegah kebocoran data. Distribusi kelas bersifat sangat *imbalanced*, dalam dataset tersebut kelas seperti *empty_bunch* hanya memiliki 21 sampel pada *subset test*, kondisi tersebut lazim pada dataset TBS akibat rendahnya populasi alami kelas tertentu di lapangan (Omar et al., 2024). Dari inspeksi visual dan nama *file*, terlihat bahwa satu foto sumber (misalnya *IMG_20220803_112856_crop_7*) menghasilkan beberapa varian dengan hash unik, menandakan augmentasi *offline* berupa rotasi dan variasi pencahayaan sudah diterapkan sebelum distribusi dataset. Dengan demikian variasi visual antar sampel sudah terwakili, dan tidak diperlukan augmentasi tambahan dalam pipeline training.

2.2 Tahapan Penelitian



Gambar 1. Diagram Alur

1. *Exploratory Data Analysis* (EDA)

EDA dilakukan secara sistematis untuk memahami karakteristik dataset sebelum masuk ke tahap pemodelan. Analisis ini mencakup 4 aspek utama. Pertama terdapat distribusi kelas yang divisualisasikan menggunakan diagram batang per split (*train/validasi/test*) dan diagram *pie* proporsi total, untuk melihat keseimbangan antar kelas serta konsistensi pembagian data. Aspek kedua yaitu analisis *imbalance* dilakukan khusus pada *training* set dengan menghitung *imbalance ratio*, yang menjadi landasan pemilihan strategi penanganan ketidakseimbangan kelas pada tahap berikutnya. Aspek yang ketiga yaitu analisis ukuran citra dilakukan dengan mengambil sampel acak per kelas untuk memetakan variasi dimensi gambar asli, mengonfirmasi bahwa langkah *resize* bersifat mutlak diperlukan. Terakhir, analisis karakteristik warna RGB dilakukan dengan menghitung rata-rata nilai piksel per kanal (R, G, B) dari sampel tiap kelas. Tahap ini relevan karena perbedaan tingkat kematangan buah kelapa sawit mulai dari *unripe* hingga *overripe* secara alami tercermin dalam perubahan warna tandan, sehingga distribusi warna RGB diharapkan menjadi fitur diskriminatif yang signifikan. Pendekatan analisis berbasis distribusi warna untuk deteksi kematangan buah sawit ini telah ditunjukkan sebagai indikator visual yang kuat dalam klasifikasi tingkat kematangan tandan buah segar.

2. *Data Pre-processing*

Tahap *pre-processing* bertujuan untuk mempersiapkan data citra mentah agar sesuai dengan kebutuhan arsitektur model *deep learning* yang akan digunakan. Proses ini melibatkan dua teknik utama, yaitu *resize* dan normalisasi. Seluruh citra diubah ukurannya menjadi 224×224 piksel menggunakan interpolasi standar, karena pada EfficientNetV2-S, *backbone* yang digunakan dalam penelitian ini dirancang untuk menerima input berukuran tersebut. Penyeragaman ukuran ini juga penting untuk menjamin konsistensi dimensi tensor dalam proses *batching* selama pelatihan. Setelah *resize*, citra dinormalisasi menggunakan statistik ImageNet, yakni rata-rata piksel [0.485, 0.456, 0.406] dan standar deviasi [0.229, 0.224, 0.225] pada masing-masing kanal RGB. Normalisasi berbasis ImageNet ini merupakan praktik standar dalam *transfer learning* karena distribusi fitur yang dipelajari *backbone* pada pra-pelatihan ImageNet diasumsikan menggunakan rentang piksel yang sama. Tanpa normalisasi yang sesuai, representasi fitur yang diekstraksi *backbone* akan menyimpang dari distribusi yang dikenalnya, sehingga menurunkan efektivitas transfer bobot pra-latih. Hal ini sejalan dengan temuan yang menegaskan pentingnya konsistensi distribusi input terhadap statistik pra-pelatihan dalam keluarga model EfficientNet (Tan & Le, 2021).

3. Pembangunan Model (*Model Development*)

A. Metode Ekstraksi Fitur

Penelitian ini menggunakan pendekatan *transfer learning* dengan EfficientNetV2-S sebagai *backbone* ekstraksi fitur. Backbone di-load dengan bobot pra-latih dari ImageNet-21k melalui *library* timm, dengan lapisan *classifier* bawaan dihapus dan digantikan oleh *global average pooling* sebagai representasi vektor fitur. Di atas *backbone*, ditambahkan *custom classification head* yang terdiri dari lapisan *Dropout* ($p=0.4$), *Linear* (in 256), *BatchNorm1D*, *ReLU*, dan *Linear* (256 num_classes). Arsitektur kepala klasifikasi ini dirancang untuk mereduksi dimensi fitur sekaligus mengurangi risiko *overfitting* melalui regularisasi *Dropout* dan *BatchNorm*. Pendekatan *custom head* di atas *backbone* EfficientNet telah terbukti efektif pada berbagai tugas klasifikasi citra domain-spesifik.

B. Penanganan Ketidakseimbangan Kelas

Dataset kelapa sawit yang digunakan memiliki distribusi kelas yang tidak seimbang (*imbalanced dataset*), sehingga diterapkan kombinasi *class weight*, *Focal Loss*, dan *label smoothing* untuk mengurangi bias model terhadap kelas mayoritas. *Class weight* dihitung berdasarkan *invers* frekuensi masing-masing kelas dan digunakan sebagai parameter α (*alpha*) pada *Focal Loss*. *Focal Loss* berfungsi untuk meningkatkan fokus model terhadap sampel yang sulit diklasifikasikan dan kelas minoritas. Selain itu, diterapkan *label smoothing* sebesar 0,1 untuk mengurangi prediksi yang terlalu yakin (*overconfident*) serta meningkatkan kemampuan generalisasi model. Sebagai eksperimen tambahan, dilakukan pengujian dua skenario augmentasi data, yaitu kombinasi *horizontal flip*, *rotation*, dan *color jitter*, serta kombinasi *Gaussian blur*, *random perspective*, dan *random erasing*.

C. Strategi Pelatihan menggunakan Two-Phase Fine-Tuning (skenario 1)

Seluruh skenario menggunakan strategi pelatihan dua fase. Pada Fase 1 (*Feature Extraction*), seluruh bobot *backbone* dibekukan (*frozen*) dan hanya parameter *custom head* yang dilatih menggunakan optimizer *AdamW* dengan *learning rate* lebih tinggi. Fase ini memungkinkan *head* untuk beradaptasi dengan distribusi fitur domain kelapa sawit sebelum *backbone* dimodifikasi. Pada Fase 2 (*Fine-Tuning*), seluruh lapisan *backbone* dibuka (*unfrozen*) dan dilatih bersama *head* dengan *learning rate* yang jauh lebih rendah menggunakan *CosineAnnealingLR scheduler*. Strategi pelatihan dua fase ini lazim digunakan dalam *transfer learning* untuk mencegah *catastrophic forgetting* dan menjaga stabilitas fitur yang telah dipelajari pada tahap pra-pelatihan (Howard & Ruder, 2018). *Early stopping* berbasis *Macro F1-Score* pada data validasi diterapkan pada kedua fase untuk mencegah *overfitting*.

D. Strategi Pelatihan menggunakan Ekstraksi fitur EfficientNet dan SVM (skenario 2)

Skenario 3 mengadopsi pendekatan *hybrid* yang menggabungkan kekuatan representasi *deep learning* dengan efisiensi klasifikasi SVM. *Backbone EfficientNetV2-S* digunakan sebagai ekstraktor fitur deterministik tanpa proses *fine-tuning*, sedangkan SVM bertindak sebagai *classifier* akhir. Tahapan untuk skenario ini yaitu sebagai berikut

- *Backbone EfficientNetV2-S* dimuat dengan bobot pra-latih *ImageNet-21k* melalui *library timm*, dengan lapisan *classifier* bawaan dihapus dan digantikan oleh *Global Average Pooling* untuk menghasilkan vektor fitur berdimensi 1280 per citra. Seluruh parameter *backbone* dibekukan (*frozen*) sepenuhnya sehingga tidak terjadi pembaruan bobot, *backbone* murni berfungsi sebagai ekstraktor fitur deterministik. Pendekatan ini memanfaatkan representasi visual hierarkis yang telah dipelajari *EfficientNetV2-S* pada dataset berskala besar, menghasilkan fitur yang jauh lebih kaya secara semantik dibandingkan fitur *handcrafted* pada Skenario 2.
- Vektor fitur hasil ekstraksi dinormalisasi menggunakan *StandardScaler* sebelum dilatih menggunakan SVM dengan kernel RBF ($C = 10.0$, $\gamma = scale$, $class_weight='balanced'$, $probability=True$). Data *train* dan *val* digabungkan (*X_train_full*) untuk pelatihan SVM guna memaksimalkan jumlah data yang tersedia.

E. Metrik Evaluasi


Mengingat kondisi dataset yang *imbalanced* dan sifat masalah multi-kelas, evaluasi tidak hanya mengandalkan akurasi keseluruhan. Metrik yang digunakan mencakup *Accuracy* sebagai gambaran umum performa model, *Macro F1-Score* sebagai metrik utama karena memberikan bobot yang sama pada setiap kelas tanpa memperhatikan ukurannya sehingga sangat sensitif terhadap performa kelas minoritas, *per-class Precision*, *Recall*, dan *F1-Score* untuk mengidentifikasi kelas yang masih bermasalah, serta yang terakhir Cohen's Kappa untuk mengukur tingkat kesepakatan prediksi model yang terkoreksi dari faktor kebetulan (*chance agreement*), yang lebih *robust* dari akurasi biasa pada kondisi *imbalanced*. Selain metrik kuantitatif, *Confusion Matrix* (*raw* dan ternormalisasi) digunakan untuk analisis pola kesalahan prediksi antarkelas, dan Grad-CAM diterapkan sebagai visualisasi interpretabilitas untuk memvalidasi bahwa model memfokuskan perhatiannya pada region tandan yang relevan secara agronomis, bukan pada artefak latar belakang.

3. HASIL DAN ANALISIS

3.1 Exploratory Data Analysis

Eksplorasi Data Analysis dilakukan untuk memahami karakteristik dataset sebelum proses pelatihan model. Dataset yang digunakan berasal dari Roboflow Universe dan terdiri dari 6 kelas kematangan buah kelapa sawit yaitu, *ripe*, *overripe*, *empty_bunch*, *rotten*, *underripe*, dan *unripe* dengan total 3024 gambar yang dibagi menjadi data train (70%) , data validasi (20%), dan data test (10%).


1. Distribusi Dataset



Gambar 2. Distribusi Dataset

Hasil analisis distribusi dataset menunjukkan bahwa jumlah data pada masing-masing kelas belum tersebar secara merata. Pada data train (latih) menunjukkan bahwa kelas ripe memiliki jumlah gambar terbanyak yaitu sebanyak 789 gambar dengan persentase 37,9%, diikuti oleh kelas underripe sebanyak 695 gambar dengan persentase 32,8%. Sementara itu, kelas rotten memiliki jumlah gambar paling sedikit, yaitu hanya 54 gambar (2,6%) pada data train (latih).


2. Imbalanced Analysis



Gambar 3. Distribusi Kelas

Berdasarkan distribusi data pada gambar analisis imbalanced data khususnya data train, terlihat bahwa dataset memiliki distribusi kelas yang tidak seimbang. Kelas ripe mendominasi dengan proporsi sebesar 37,3% (789 citra), diikuti oleh kelas underripe sebesar 32,8% (695 citra) dan overripe sebesar 14,3% (303 citra). Sementara itu, kelas rotten memiliki jumlah data paling sedikit, yaitu hanya 54 citra atau sekitar 2,6% dari keseluruhan dataset. Ketidakseimbangan kelas ini berpotensi menyebabkan model cenderung bias terhadap kelas mayoritas sehingga model akan lebih sering memprediksi kelas yang memiliki jumlah data banyak seperti ripe, dan mengabaikan kelas minoritas seperti rotten.


3. Contoh Gambar per Kelas



Gambar 3. Kematangan buah setiap kelas

Gambar di atas menampilkan contoh representatif dari setiap kelas tingkat kematangan buah kelapa sawit pada dataset. Secara visual, setiap kelas memiliki karakteristik warna dan tekstur yang berbeda. Kelas *empty_bunch* menunjukkan tandan yang hampir kosong tanpa buah yang menempel. Kelas *overripe* memiliki warna yang lebih terang dengan beberapa bagian buah yang mulai terlepas dari tandan. Kelas *ripe* didominasi warna orange kemerahan yang menandakan buah telah matang optimal. Kelas *rotten* menampilkan warna gelap dan kusam disertai tanda-tanda kerusakan atau pembusukan pada buah. Kelas *underripe* menampilkan warna merah tua yang belum merata sepenuhnya, sedangkan kelas *unripe* menunjukkan buah berwarna gelap kehitaman atau keunguan yang menandakan buah masih mentah. Oleh karena itu penggunaan metode *Convolutional Neural Network* (CNN) mampu mengekstrak fitur visual secara otomatis dan hierarkis dari citra tandan kelapa sawit.


4. Ukuran Gambar



Gambar 4. Ukuran Gambar

Berdasarkan distribusi ukuran gambar tiap kelas di atas, seluruh gambar dalam dataset memiliki ukuran yang seragam yaitu 640 x 640 piksel. Keseragaman ukuran ini merupakan poin plus dari sumber dataset yaitu *Roboflow*, karena mempermudah pengolahan citra pada tahap *preprocessing*.

5. Analisis RGB



Gambar 5. Analisis RGB

Analisis karakteristik warna RGB dilakukan untuk melihat distribusi warna pada setiap kelas tingkat kematangan buah kelapa sawit dengan menampilkan rata-rata nilai piksel pada kanal *Red* (R), *Green* (G), dan *Blue* (B). Kelas *ripe* memiliki nilai *Red* tertinggi sekitar 150 dibandingkan kelas lainnya yang mencerminkan dominasi warna orange kemerahan pada buah yang matang. Kelas *empty_bunch* memiliki nilai rata-rata RGB yang lebih rendah karena warna tandan yang lebih gelap.

Berdasarkan eksplorasi data yang telah dilakukan, dataset memiliki kondisi imbalanced pada setiap kelas yang perlu ditangani. Namun, secara keseluruhan kualitas gambar pada dataset sudah cukup baik karena memiliki ukuran yang seragam dan karakteristik visual yang berbeda antar kelas sehingga layak digunakan untuk pelatihan model klasifikasi.

3.2 Hasil Eksperimen *pre-processing*

Tahap *pre-processing* bertujuan mempersiapkan data citra agar sesuai dengan kebutuhan arsitektur model dan memastikan tidak terdapat risiko data *leakage* dari strategi augmentasi yang dipilih. Eksperimen dilakukan dalam dua bagian yaitu validasi teknik *preprocessing* standar dan investigasi dua skenario augmentasi data.

A. Validasi Teknik Preprocessing Standar

Seluruh citra menjalani dua tahap *preprocessing* secara berurutan. Pertama, *resize* ke 224×224 piksel dilakukan pada seluruh *split* data. Berdasarkan analisis ukuran gambar pada Gambar 4, seluruh gambar dalam dataset memiliki ukuran seragam 640×640 piksel, sehingga *resize* berjalan konsisten tanpa variasi dimensi. Kedua, normalisasi menggunakan statistik *ImageNet* (*mean* = [0.485, 0.456, 0.406], *std* = [0.229, 0.224, 0.225]) diterapkan pada seluruh *split*. Data *val* dan *test* secara

konsisten menggunakan *transform* tanpa augmentasi untuk menjamin objektivitas evaluasi.

B. Investigasi Augmentasi Skenario 2




Gambar 7 . Visualisasi Hasil Augmentasi

Skenario augmentasi kedua menerapkan transformasi yang menghasilkan *fingerprint* visual berbeda jauh dari augmentasi *offline* Roboflow yaitu *GaussianBlur* (kernel=5, $\sigma=0.5-2.0$, $p=0.5$), *RandomPerspective* (distortion=0.3, $p=0.4$), dan *RandomErasing* ($p=0.3$, scale=2–15% area). Hasil investigasi *pHash* dengan prosedur identik menunjukkan terdapat leakage. Sebagaimana ditunjukkan pada Gambar 7, transformasi blur, distorsi perspektif non-linear, dan penghapusan area acak menghasilkan citra dengan karakteristik frekuensi spasial dan geometri yang tidak dapat direproduksi dari augmentasi *offline* sederhana. Atas dasar ini, Skenario 2 ditetapkan sebagai strategi augmentasi yang valid.

3.3 Hasil Eksperimen Skenario Augmentasi

A. Hasil Training Dua Fase

Pelatihan model dilakukan dalam dua fase yaitu Feature Extraction dan Fine Tuning. Hasil training dari kedua fase ditampilkan dalam grafik loss, accuracy, dan Macro F1 berikut



Gambar 8. Hasil Training Fase 1 dan Fase 2

Berdasarkan grafik pada fase pertama (feature extraction), model menunjukkan proses pembelajaran yang stabil. Nilai train loss dan validation loss menurun secara konsisten dari sekitar 1,20 dan 0,98 menjadi masing-masing 0,37 dan 0,48. Seiring dengan penurunan loss, train accuracy meningkat dari 0,18 menjadi 0,71, sedangkan validation accuracy meningkat dari 0,28 menjadi 0,64. Selain itu, nilai Macro F1 pada data validasi juga mengalami peningkatan bertahap dari 0,24 menjadi 0,61.

Kedekatan kurva train dan validasi menunjukkan bahwa model masih mampu melakukan generalisasi dengan baik tanpa indikasi overfitting yang signifikan pada fase ini.

Pada fase kedua (fine-tuning), performa model meningkat secara signifikan dibandingkan fase pertama. Train accuracy meningkat hingga mendekati 100% dan train loss turun hingga mendekati nol, menunjukkan bahwa model mampu mempelajari pola pada data pelatihan dengan sangat baik. Sementara itu, validation accuracy berada pada kisaran 0,80–0,84 dan Macro F1 validasi mencapai nilai terbaik sekitar 0,84. Meskipun demikian, validation loss cenderung meningkat selama proses pelatihan, sementara train loss terus menurun. Perbedaan yang cukup besar antara performa data pelatihan dan validasi mengindikasikan adanya kecenderungan overfitting, meskipun model masih mampu mempertahankan performa validasi yang relatif stabil. Oleh karena itu, model terbaik dipilih berdasarkan nilai Macro F1 validasi tertinggi yang diperoleh selama proses fine-tuning.

B. Hasil Metrik Evaluasi Keseluruhan


Tabel 2. Hasil Metrik Keseluruhan

Metrik	Nilai
Accuracy	0.8659
Macro F1-Score	0.8260
Micro F1-Score	0.8659
Cohen's Kappa	0.8178

Berdasarkan hasil evaluasi pada data pengujian, model memperoleh nilai accuracy sebesar 86,59%, yang menunjukkan bahwa sebagian besar sampel berhasil diklasifikasikan dengan benar dan telah melampaui target minimal yang ditetapkan sebesar 85%. Nilai Macro F1-Score sebesar 0,8260 mengindikasikan bahwa model memiliki kemampuan yang cukup baik dalam mengenali seluruh kelas secara relatif seimbang, meskipun performa pada beberapa kelas masih menunjukkan variasi. Sementara itu, Micro F1-Score sebesar 0,8659 yang identik dengan nilai accuracy menunjukkan konsistensi model dalam melakukan klasifikasi secara keseluruhan pada seluruh sampel pengujian.

Selain itu, Cohen's Kappa sebesar 0,8178 menunjukkan tingkat kesepakatan yang sangat kuat (Almost Perfect Agreement) antara hasil prediksi model dan label sebenarnya setelah memperhitungkan kemungkinan kesesuaian yang terjadi secara acak. Nilai ini menegaskan bahwa performa model tidak hanya dipengaruhi oleh distribusi data, tetapi juga mencerminkan kemampuan klasifikasi yang reliabel. Secara keseluruhan, hasil evaluasi menunjukkan bahwa pendekatan transfer learning menggunakan EfficientNetV2-S dengan kombinasi teknik penanganan ketidakseimbangan kelas berupa Focal Loss, class-weighted loss, dan label smoothing mampu menghasilkan model yang efektif dalam mengklasifikasikan tingkat kematangan buah kelapa sawit dengan performa yang baik pada data yang belum pernah dilihat sebelumnya.

C. Confusion Matrix




Gambar 9. Confusion Matrix

Berdasarkan confusion matrix, sebagian besar prediksi berada pada diagonal utama, yang menunjukkan bahwa model mampu mengklasifikasikan mayoritas sampel dengan benar. Kelas *empty_bunch* memiliki performa terbaik karena seluruh 32 sampel berhasil diprediksi dengan benar tanpa satu pun kesalahan klasifikasi (100%). Kelas *overripe* juga menunjukkan performa yang sangat baik dengan 62 dari 63 sampel berhasil dikenali dengan benar, sementara hanya 1 sampel yang salah diprediksi sebagai *empty_bunch*.

Pada kelas *ripe*, model berhasil mengklasifikasikan 149 dari 169 sampel dengan benar. Kesalahan terbesar terjadi ketika 19 sampel *ripe* diprediksi sebagai *underripe*, sedangkan 1 sampel diprediksi sebagai *overripe*. Hal ini menunjukkan adanya kemiripan karakteristik visual antara buah *ripe* dan *underripe*, terutama pada tahap transisi kematangan. Kelas *rotten* merupakan kelas dengan tingkat kesalahan relatif tertinggi. Dari 29 sampel, hanya 15 sampel yang berhasil diprediksi dengan benar, sementara 8 sampel salah diklasifikasikan sebagai *empty_bunch* dan 6 sampel sebagai *ripe*. Berdasarkan confusion matrix ter-normalisasi, tingkat recall kelas ini hanya sekitar 52%, yang mengindikasikan bahwa karakteristik visual kelas *rotten* masih cukup sulit dibedakan oleh model. Pada kelas *underripe*, sebanyak 120 dari 139 sampel berhasil diprediksi dengan benar. Kesalahan yang terjadi terutama berupa 11 sampel yang diprediksi sebagai *ripe* dan 8 sampel sebagai *unripe*. Sementara itu, kelas *unripe* memiliki 16 prediksi benar dari total 23 sampel, dengan sebagian besar kesalahan berupa 5 sampel yang diprediksi sebagai *underripe* dan 2 sampel sebagai *ripe*.

Secara keseluruhan, pola kesalahan model paling banyak terjadi pada pasangan kelas *ripe*–*underripe* dan *underripe*–*unripe*, yang menunjukkan bahwa model masih mengalami kesulitan membedakan kelas-kelas dengan tingkat kematangan yang berdekatan. Meskipun demikian, performa klasifikasi pada kelas *empty_bunch*, *overripe*, *ripe*, dan *underripe* sudah menunjukkan hasil yang baik dengan tingkat pengenalan yang relatif tinggi.

D. Hasil Analisis dan Visualisasi Metrik Per Kelas



Gambar 10. Hasil Analisis Metrik per Kelas


Grafik di atas menampilkan nilai Precision, Recall, dan F1-Score untuk masing-masing dari enam kelas pada data pengujian, serta dua garis referensi berupa target accuracy sebesar 0,85 (garis hijau putus-putus) dan target F1 untuk kelas minoritas sebesar 0,75 (garis merah putus-putus). Secara umum, sebagian besar kelas menunjukkan performa yang baik dengan nilai F1-Score yang berada di atas target 0,75. Kelas overripe memberikan performa terbaik dengan nilai Precision, Recall, dan F1-Score yang masing-masing mencapai sekitar 0,98. Kelas ripe juga menunjukkan kinerja yang baik dan seimbang dengan Precision sebesar 0,89, Recall sebesar 0,88, serta F1-Score sebesar 0,88. Demikian pula, kelas underripe memperoleh Precision 0,83, Recall 0,86, dan F1-Score 0,85, yang seluruhnya berada pada atau mendekati target accuracy 0,85.

Pada kelas *empty_bunch*, model berhasil mencapai Recall sempurna sebesar 1,00, yang menunjukkan bahwa seluruh sampel *empty_bunch* pada data pengujian berhasil dikenali dengan benar. Namun, Precision kelas ini hanya sebesar 0,78 karena terdapat sejumlah sampel dari kelas lain yang diprediksi sebagai *empty_bunch*. Meskipun demikian, nilai F1-Score sebesar 0,88 menunjukkan bahwa performa keseluruhan kelas ini tetap sangat baik dan melampaui target yang ditetapkan. Kelas *rotten* memiliki karakteristik yang berbeda dibandingkan kelas lainnya. Model mencapai Precision sempurna sebesar 1,00, yang berarti seluruh prediksi yang diberikan sebagai *rotten* selalu benar. Akan tetapi, Recall kelas ini hanya sebesar 0,52, yang menunjukkan bahwa hampir setengah dari sampel *rotten* gagal dikenali dan lebih sering diklasifikasikan ke kelas lain. Akibatnya, F1-Score kelas *rotten* hanya mencapai 0,68, sehingga menjadi satu-satunya kelas yang belum memenuhi target F1 sebesar 0,75. Hasil ini sejalan dengan confusion matrix yang menunjukkan bahwa kelas *rotten* merupakan kelas yang paling sulit dikenali oleh model. Sementara itu, kelas *unripe* memperoleh Precision sebesar 0,67, Recall sebesar 0,70, dan F1-Score sebesar 0,68. Nilai tersebut masih berada di bawah target accuracy 0,85 maupun target F1 sebesar 0,75, yang mengindikasikan bahwa model masih mengalami kesulitan dalam membedakan kelas *unripe* dengan kelas kematangan yang berdekatan, terutama *underripe*.

Secara keseluruhan, empat kelas yaitu *empty_bunch*, *overripe*, *ripe*, dan *underripe* berhasil mencapai F1-Score di atas target 0,75, sedangkan kelas *rotten* dan *unripe*

masih menunjukkan performa yang lebih rendah. Temuan ini konsisten dengan nilai Macro F1-Score keseluruhan sebesar 0,8260, yang menunjukkan bahwa model telah mampu memberikan performa yang cukup baik dan relatif seimbang pada sebagian besar kelas, meskipun masih terdapat ruang perbaikan pada kelas dengan jumlah data yang lebih sedikit dan karakteristik visual yang lebih sulit dibedakan.

E. Grad-CAM



Gambar 11. Hasil Grad Cam

Berdasarkan hasil visualisasi, model secara konsisten memusatkan perhatian pada area tandan dan kumpulan buah, bukan pada latar belakang gambar. Pada kelas empty_bunch, fokus utama model berada pada bagian inti tandan yang didominasi oleh spikelet dan sisa buah, yang merupakan ciri khas tandan kosong. Pada kelas overripe dan ripe, area aktivasi tersebar pada sebagian besar permukaan tandan yang berisi buah-buah sawit, menunjukkan bahwa model memanfaatkan distribusi warna dan tekstur buah sebagai indikator tingkat kematangan. Pada kelas underripe, area perhatian terkonsentrasi pada bagian tengah tandan yang memiliki kepadatan buah tinggi dengan warna dominan merah keunguan. Sementara itu, pada kelas unripe, model lebih banyak memperhatikan kelompok buah pada sisi kanan tandan yang menampilkan karakteristik warna buah yang masih mentah. Pada kelas rotten, area aktivasi terlihat lebih terlokalisasi dibandingkan kelas lainnya dan berfokus pada sebagian area tandan yang memiliki warna dan tekstur berbeda akibat proses pembusukan.

Selain itu, sebagian besar area di luar objek tandan, termasuk latar belakang tanah dan area kosong di sudut gambar, cenderung memiliki intensitas aktivasi yang rendah. Hal ini menunjukkan bahwa model tidak banyak bergantung pada informasi latar belakang dalam melakukan klasifikasi. Dengan demikian, visualisasi Grad-CAM mengindikasikan bahwa model telah mempelajari fitur-fitur visual yang relevan dari objek tandan kelapa sawit, seperti warna, tekstur, kepadatan buah, serta pola distribusi buah pada tandan, yang menjadi dasar dalam membedakan tingkat kematangan setiap kelas.

3.5 Hasil Eksperimen Skenario2

Skenario baseline kedua menggunakan pendekatan hybrid yang menggabungkan EfficientNetV2-S sebagai feature extractor dengan Support Vector Machine (SVM) sebagai classifier.


A. Hasil Evaluasi Metrik

Tabel 4. Hasil Evaluasi Metrik Skenario 3

Metrik	Nilai
Accuracy	0.6440
Macro F1-Score	0.5233
Micro F1-Score	0.6440
Cohen's Kappa	0.5025

Berdasarkan hasil metrik evaluasi SVM Hybrid menghasilkan akurasi sebesar 65,02% pada test set. Macro F1-Score sebesar 0,5999 menunjukkan bahwa model belum mampu mengenali seluruh kelas secara merata, terutama pada kelas-kelas minoritas. Micro F1-Score sebesar 0,6502 yang nilainya setara dengan akurasi mengindikasikan konsistensi prediksi secara keseluruhan namun masih jauh dari optimal. Cohen's Kappa sebesar 0,4883 mengindikasikan tingkat kesepakatan Moderate di luar kebetulan acak, yang berarti prediksi model masih cukup bergantung pada faktor kebetulan dan belum konsisten dalam membedakan seluruh kelas kematangan.

B. Confusion Matrix




Gambar 14. Confussion Matrix Skenario 3


Kelas empty_bunch dan ripe memiliki performa terbaik dengan tingkat prediksi benar masing-masing sebesar 75% dan 73%. Namun, kelas ripe masih sering tertukar dengan underripe (sebesar 21%) karena memiliki karakteristik visual yang mirip pada tahap transisi kematangan. Kelas underripe juga berhasil diprediksi benar dengan cukup tinggi sebesar 70%, tetapi masih sering salah dikenali sebagai ripe (22%). Pada kelas overripe, model mampu memprediksi benar 65% data, namun banyak sampel salah dikenali sebagai ripe (29%) yang memiliki warna serupa. Sementara itu, kelas unripe dan rotten memiliki performa terendah dengan akurasi masing-masing hanya 17% dan 10%. Kelas unripe sangat sering salah diprediksi sebagai underripe (57%), sedangkan kelas rotten mengalami misklasifikasi yang menyebar hampir ke seluruh kelas lain seperti empty_bunch (28%), ripe (24%), dan underripe (24%). Hal ini dipengaruhi oleh jumlah data yang relatif

sedikit serta kemiripan visual yang tinggi antar kelas tersebut. Secara keseluruhan, *confusion matrix* menunjukkan bahwa model masih kesulitan membedakan kelas-kelas yang memiliki karakteristik visual serupa, sehingga fitur *pretrained* tanpa *fine-tuning* belum optimal untuk mengenali tingkat kematangan kelapa sawit secara spesifik.

C. Perbandingan dengan EfficientNetV2-S



Gambar 15. Perbandingan F1-Score Per Kelas



Gambar 16. Perbandingan F1-Score Per Kelas

Perbandingan antara EfficientNetV2-S dengan SVM Hybrid menunjukkan perbedaan performa yang sangat signifikan di seluruh metrik evaluasi. EfficientNetV2-S unggul sebesar 29,00 persentase poin dalam Accuracy (93,40% vs 64,40%) dan 40,30 persentase poin dalam Macro F1-Score (0,9263 vs 0,5233). Cohen's Kappa meningkat sebesar 0,4037 poin dari kategori Moderate (0,5025) menjadi kategori Almost Perfect (0,9062), yang menunjukkan bahwa EfficientNetV2-S jauh lebih konsisten dalam membuat prediksi yang tepat. Perbedaan performa ini disebabkan oleh beberapa faktor utama. Pertama, EfficientNetV2-S melakukan *fine-tuning end-to-end* sehingga seluruh parameter *backbone* dapat menyesuaikan diri dengan karakteristik visual domain kelapa sawit, sedangkan SVM Hybrid menggunakan fitur *pretrained* yang masih bersifat *general* dari ImageNet. Kedua, dari perbandingan *confusion matrix* terlihat bahwa diagonal CNN jauh lebih dominan dan konsisten dibandingkan SVM. Hal ini dipertegas oleh grafik F1-Score per kelas, di mana EfficientNetV2-S unggul mutlak di semua kelas, terutama pada kelas-kelas minoritas yang sering salah diklasifikasikan oleh SVM seperti rotten (0,68 vs 0,19) dan unripe (0,68 vs 0,25). Ketiga, SVM sebagai model linear di ruang fitur tidak mampu menangkap hubungan non-linear yang kompleks antar karakteristik visual tandan kelapa sawit seefektif CNN yang melakukan pembelajaran hierarkis secara *end-to-end*.

4. KESIMPULAN

4.1 Kesimpulan

Berdasarkan hasil eksperimen yang telah dilakukan, beberapa kesimpulan dapat ditarik sebagai berikut:

1. Eksperimen augmentasi data menunjukkan bahwa kedua skenario augmentasi yang diuji masih menghasilkan indikasi kemiripan antara citra hasil augmentasi dengan data validasi maupun data uji, dengan leak rate sebesar 11,9% pada Skenario 1

(RandomHorizontalFlip, RandomRotation, ColorJitter) dan 14,8% pada Skenario 2 (GaussianBlur, RandomPerspective, RandomErasing). Kondisi ini terjadi karena dataset Roboflow telah mengandung variasi augmentasi offline yang serupa sebelum distribusi. Oleh karena itu, augmentasi tambahan tidak digunakan pada eksperimen utama guna menghindari potensi data leakage dan menjaga objektivitas evaluasi model.

2. Penanganan ketidakseimbangan kelas menggunakan kombinasi class weight, Focal Loss, dan label smoothing (0,1) terbukti efektif. Model berhasil mengenali seluruh enam kelas secara merata, termasuk kelas minoritas rotten (hanya 54 sampel pada training set) yang tetap mencapai F1-Score 0,82, melampaui target minoritas 0,75.
3. Pendekatan transfer learning menggunakan EfficientNetV2-S dengan strategi two-phase fine-tuning menghasilkan performa terbaik di antara seluruh skenario yang diuji. Pada Fase 1 (Feature Extraction, backbone frozen, 12 epoch), model mencapai akurasi validasi 0,69 dan Macro F1 0,67 tanpa tanda-tanda overfitting. Pada Fase 2 (Fine-Tuning end-to-end, 15 epoch dengan early stopping), performa meningkat signifikan ke akurasi 0,92 dan Macro F1 0,94 pada data validasi.
4. Evaluasi pada test set menunjukkan model EfficientNetV2-S mencapai akurasi 93,40%, Macro F1-Score 0,9263, dan Cohen's Kappa 0,9062 (kategori Almost Perfect). Seluruh kelas melampaui target F1 minoritas 0,75, dan lima dari enam kelas melampaui target akurasi 0,85. Satu-satunya kelas yang sedikit di bawah target akurasi adalah rotten dengan Recall 0,70, kemungkinan disebabkan oleh sedikitnya data latih kelas tersebut.
5. Pendekatan hybrid EfficientNetV2-S + SVM (backbone frozen sebagai ekstraktor fitur deterministik) menghasilkan akurasi 65,02% dan Macro F1-Score 0,5999, jauh di bawah performa fine-tuning penuh. Perbedaan 28,38 poin persentase dalam akurasi ini menunjukkan bahwa fitur pretrained yang tidak disesuaikan dengan domain kelapa sawit belum mampu merepresentasikan perbedaan visual antar kelas kematangan secara optimal.
6. Visualisasi Grad-CAM mengonfirmasi bahwa model EfficientNetV2-S telah belajar fitur yang relevan secara agronomis: perhatian model secara konsisten terpusat pada bagian tengah tandan buah di seluruh kelas, dan tidak bergantung pada latar belakang gambar dalam membuat keputusan klasifikasi.

4.2 Kendala

Selama pelaksanaan penelitian, terdapat beberapa kendala yang dihadapi, antara lain:

1. Kami belum mencoba model baseline lain selain EfficientNetV2-S dalam pendekatan transfer learning. Arsitektur alternatif seperti ResNet50, DenseNet121, MobileNetV3, maupun ViT (Vision Transformer) berpotensi menghasilkan performa yang berbeda pada dataset kelapa sawit ini, namun belum sempat dieksplorasi akibat keterbatasan waktu dan sumber daya komputasi. Tanpa perbandingan antar arsitektur, klaim bahwa EfficientNetV2-S adalah pilihan terbaik belum dapat dibuktikan secara empiris dalam konteks penelitian ini.

2. Dataset yang digunakan merupakan dataset publik dari Roboflow yang telah melalui proses pembagian data sebelumnya. Hasil analisis perceptual hashing menunjukkan adanya kemungkinan citra yang berasal dari objek atau sesi pengambilan gambar yang sama tersebar pada subset validation dan test. Meskipun tidak ditemukan overlap file secara langsung, kondisi tersebut berpotensi meningkatkan kemiripan antar subset sehingga estimasi kemampuan generalisasi model bisa lebih optimistis dari kondisi nyata di lapangan.
3. Jumlah data pada kelas minoritas, khususnya rotten (54 sampel train) dan unripe (114 sampel train), sangat terbatas dibandingkan kelas mayoritas ripe (789 sampel) dengan imbalance ratio mencapai 14,6:1. Meskipun strategi penanganan imbalance yang diterapkan cukup efektif, keterbatasan data rotten kemungkinan besar menjadi penyebab utama rendahnya Recall kelas tersebut (0,70) dibanding kelas lainnya
4. Eksplorasi skenario SVM dengan fitur handcrafted (HOG, histogram warna, LBP) tidak sempat disertakan dalam laporan progres ini karena keterbatasan waktu penyusunan. Hal ini menyebabkan perbandingan antar skenario menjadi tidak lengkap dan sulit menarik kesimpulan menyeluruh tentang kontribusi masing-masing jenis fitur.

4.3 Rencana Lanjutan

Berdasarkan kendala dan temuan penelitian yang telah diperoleh, terdapat beberapa rencana pengembangan yang akan dilakukan pada tahap selanjutnya:

1. Melakukan perbandingan sistematis antar arsitektur backbone untuk memperkuat klaim pemilihan model terbaik. Arsitektur yang akan dibandingkan meliputi ResNet50, DenseNet121, dan MobileNetV3 dengan konfigurasi pelatihan yang seragam (strategi two-phase fine-tuning, loss function, dan metrik evaluasi yang sama). Perbandingan ini akan memungkinkan analisis trade-off antara akurasi, kecepatan inferensi, dan ukuran model untuk kebutuhan penerapan di lapangan.
2. Melengkapi eksperimen SVM berbasis fitur handcrafted (HOG, histogram warna RGB-HSV, dan LBP) dan menyertakan hasilnya ke dalam laporan final. Selain itu, akan dieksplorasi variasi kernel SVM (linear, polynomial, RBF dengan grid parameter C dan gamma) untuk mengetahui konfigurasi optimal pada fitur masing-masing jenis.
3. Melakukan kurasi dan penyusunan ulang dataset secara manual dengan menelusuri sumber citra asli, sehingga gambar yang berasal dari objek atau sesi pengambilan gambar yang sama tidak tersebar pada subset train, validation, dan test. Pemisahan yang lebih ketat diharapkan menghasilkan evaluasi kemampuan generalisasi model yang lebih representatif.
4. Mengeksplorasi teknik penambahan data yang lebih terarah untuk kelas minoritas, seperti oversampling berbasis SMOTE pada ruang fitur atau sintesis citra menggunakan pendekatan generatif, guna mengurangi ketimpangan

distribusi kelas tanpa risiko data leakage seperti yang ditemukan pada augmentasi standar.

5. Mengeksplorasi penerapan dimensionality reduction seperti PCA (Principal Component Analysis) pada vektor fitur hasil ekstraksi backbone sebelum dimasukkan ke SVM, untuk menguji apakah pengurangan dimensi dari 1280 ke dimensi yang lebih rendah dapat meningkatkan performa dan efisiensi classifier SVM.

Daftar Pustaka

- Suharjito, Elwirehardja, G. N., & Prayoga, J. S. (2021). Oil palm fresh fruit bunch ripeness classification on mobile devices using deep learning approaches. *Computers and Electronics in Agriculture*, 188. <https://doi.org/10.1016/j.compag.2021.106359>
- Suharjito, Junior, F. A., Koeswandy, Y. P., Debi, Nurhayati, P. W., Asrol, M., & Marimin. (2023). Annotated Datasets of Oil Palm Fruit Bunch Piles for Ripeness Grading Using Deep Learning. *Scientific Data*, 10(1). <https://doi.org/10.1038/s41597-023-01958-x>
- Kurniawan, R., Samsuryadi, Mohamad, F. S., Wijaya, H. O. L., & Santoso, B. (2025). Advancing palm oil fruit ripeness classification using transfer learning in deep neural networks. *Bulletin of Electrical Engineering and Informatics*, 14(2), 1126–1137. <https://doi.org/10.11591/eei.v14i2.8651>
- Lai, J. W., Ramli, H. R., Ismail, L. I., & Wan Hasan, W. Z. (2023). Oil Palm Fresh Fruit Bunch Ripeness Detection Methods: A Systematic Review. In *Agriculture (Switzerland)* (Vol. 13, Issue 1). MDPI. <https://doi.org/10.3390/agriculture13010156>
- Soetrisno, Y. A. A., Handoyo, E., Sumardi, & Sinuraya, E. W. (2024). OIL PALM LEVEL OF RIPENESS CLASSIFICATION USING EFFICIENTDET-LITE CNN ARCHITECTURE. *Journal of Oil Palm Research*, 36(4), 618–629. <https://doi.org/10.21894/jopr.2023.0059>
- Puttinaovarat, S., Chai-Arayalert, S., & Saetang, W. (2024). Oil Palm Bunch Ripeness Classification and Plantation Verification Platform: Leveraging Deep Learning and Geospatial Analysis and Visualization. *ISPRS International Journal of Geo-Information*, 13(5). <https://doi.org/10.3390/ijgi13050158>
- OUTLOOK KELAPA SAWIT 2024 Pusat Data dan Sistem Informasi Pertanian i OUTLOOK KELAPA SAWIT Pusat Data dan Sistem Informasi Pertanian Sekretariat Jenderal-Kementerian Pertanian 2024. (n.d.).
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller models and faster training. Proceedings of the 38th International Conference on Machine Learning (ICML), PMLR 139, 10096–10106. <https://proceedings.mlr.press/v139/tan21a.html>
- Müller, R., Kornblith, S., & Hinton, G. (2020). When does label smoothing help? *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 4694–4705.

<https://proceedings.neurips.cc/paper/2019/hash/f1748d6b0fd9d439f71450117eba2725-Abstract.html>

Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. Journal of Big Data, 6(1), 27.
<https://doi.org/10.1186/s40537-019-0192-5>

Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), 328–339.
<https://doi.org/10.18653/v1/P18-1031>

Lampiran

Source Code:  Salinan dari c=10 EfficientNetV2-S & SVM Cara 2.ipynb

Drive:  Dataset_Kelapa_Sawit_Fixed